

---

# Sprawozdanie z ćwiczenia nr 7 i 8

---

Autorzy	Nr grupy	Data	Ocena
Tomasz Cudziło Robert Wróblewski	2	2013-03-27 10:15	

---

## 1 Cel ćwiczenia

W ramach ćwiczenia mieliśmy zapoznać się metodami skalowania i selekcji stosowanych w algorytmach genetycznych. Symulując działanie algorytmu genetycznego mieliśmy zaobserwować wpływ wybranych metod skalowania funkcji przystosowania i selekcji na efektywność działania algorytmu genetycznego aproksymującego funkcję wielu zmiennych.

## 2 Przebieg ćwiczenia

### 2.1 Wyznaczenie funkcji przystosowania

Przypisana nam została funkcja celu o postaci:

$$f_c = 4 \cos(x_1^2) + 6 \cos(x_3) - 20x_2^2 + 3x_1^3 - 5$$

gdzie  $x_1 \in [-6; 10]$ ,  $x_2 \in [-2; 4]$  oraz  $x_3 \in [-3; 7]$ .

Otrzymany zestaw danych losowych przeskalowaliśmy na trzy zbiory argumentów, tak by zawarte były w dziedzinie funkcji celu. Następnie stworzyliśmy funkcję przystosowania poprzez dodanie do niej dwukrotnie wartości absolutnej z najmniejszej wartości przyjmowanej przez funkcję celu:

$$f_p = f_c + 2 \left| \min_{x_1, x_2, x_3} (f_c) \right|$$

Wyliczone wartości znajdują się w zakładce *Przystosowanie* w załączonym skoroszybie.

### 2.2 Skalowanie funkcji przystosowania

Następnie wyliczyliśmy parametry potrzebne do przeprowadzenia skalowań funkcji przystosowania dwoma wybranymi metodami:

1. Metodą liniową;
2. Metodą  $\sigma$ -odcięcia.


Wyliczenia przeprowadziliśmy zgodnie z instrukcjami ze skryptu i można je znaleźć odpowiednio w ukrytych zakładkach skoroszytu *Wyliczenia skalowania liniowego* i *Wyliczenia skalowania sigma*.

### 2.3 Przeprowadzenie selekcji


W efekcie otrzymaliśmy trzy zestawy wartości funkcji przystosowania, dwa po skalowaniu i ślełą próbę bez skalowania. Dla każdego ze zbiorów wykonaliśmy selekcję:

1. Metodą losową z powtórzeniami;
2. Metodą deterministyczną.


Otrzymaliśmy w ten sposób sześć zestawów danych do analizy. Dla selekcji losowej do wyboru kopii użyliśmy danych losowych otrzymanych na zajęciach.




Rysunek 1 Wykres porównujący wartość funkcji przystosowania dla generacji zależnie od dobranej metody skalowania.



Rysunek 2 Porównanie metod selekcji dla przystosowania osobników bez skalowania.



Rysunek 3 Porównanie metod selekcji dla przystosowania osobników ze skalowaniem liniowym.



Rysunek 4 Porównanie metod selekcji dla przystosowania osobników ze skalowaniem sigma-odcięcia.

## 3 Otrzymane wyniki

### 3.1 Porównanie metod skalowania funkcji przystosowania

Rysunek 1 na stronie 2 przedstawia porównanie wartości przyjmowanych przez funkcję przystosowania zależnie od wybranej metody skalowania. Wykres pomija średnią wartość dla skalowania liniowego, jest ona równa średniej wartości dla przypadku bez skalowania.

#### 3.1.1 Skalowanie metodą liniową

Wpływ skalowania metodą liniową jest wyraźny. Funkcja przystosowania zwraca mało rozproszone wartości dla całej populacji. Osobniki o przystosowaniu pierwotnym odbiegającym od średniego przystosowania populacji, po skalowaniu otrzymują przystosowanie bliższe średniej całej populacji. Widoczne jest to w wartości standardowego odchylenia przystosowania po skalowaniu, które wynosi 310,25. Jest to znacznie niższy wynik od standardowego odchylenia dla przystosowania bez skalowania równego 880,07.

#### 3.1.2 Skalowanie metodą $\sigma$ -odcięcia

Skalowanie metodą  $\sigma$ -odcięcia obniżyło wartości zwracane przez funkcję przystosowania. Dla każdego osobnika różnica wartości w porównaniu do przystosowań pierwotnych jest równomierna. Osobniki o najniższym przystosowaniu pierwotnym po skalowaniu otrzymują przystosowanie bliskie zeru. W praktyce oznacza to odebranie tym osobnikom możliwości stworzenia potomków, ponieważ będą miały równą lub bliską zeru szansę na wybór podczas etapu selekcji.

Przesunięcie wartości funkcji przystosowania wydaje się być jedynym efektem skalowania metodą  $\sigma$ -odcięcia. Rozproszenie przystosowania w populacji pozostaje bez zmian w stosunku do braku skalowania; standardowe odchylenie wynosi odpowiednio 863,00 do 880,07.

### 3.2 Porównanie metod selekcji

#### 3.2.1 Selekcja losowa z powtórzeniami

Selekcja losowa powoduje nietypowy wybór osobników tworzących kolejne generacje. Jej nieprzewidywalność jest szczególnie widoczna na Rysunek 3. Selekcja deterministyczna skupia kolejne generacje wokół jednego rozwiązania. Selekcja losowa natomiast urozmaica kolejne generacje, promując osobniki nawet o przeciętym przystosowaniu.

#### 3.2.2 Selekcja deterministyczna

Wykazuje się przewidywalnym i gradualnym rozłożeniem liczby kopii osobników, adekwatnie do ich przystosowania. Osobniki dobrze przystosowane dostają większą szansę na wybór podczas etapu selekcji niż osobniki gorzej przystosowane.

## 4 Wnioski

### 4.1 Metody skalowania funkcji przystosowania

Metoda skalowania liniowego wydaje się być przydatna gdy algorytm bardzo szybko zbiega do ekstremum lokalnego funkcji celu, a chcemy tego uniknąć. Skalowanie liniowe w takiej sytuacji zapobiegnie utknięciu algorytmu wokół jednego rozwiązania. Pozwoli za to, na utworzenie osobników bliskich rozwiązaniom spoza aktualnego ekstremum. Jest to możliwe przez zmniejszanie przewagi osobników wyjątkowo dobrze przystosowanych. Efekt ten można zauważyć na Rysunek 1 ze strony 2. Należy też zauważyć, że skalowanie liniowe może spowodować wydłużenie znajdowania rozwiązań przez algorytm. Skalowanie liniowe przyznaje lepsze przystosowanie osobnikom o niskim przystosowaniu pierwotnym. Może to doprowadzić do sytuacji, gdzie wszystkie osobniki będą

wykazywały się przystosowaniem bliskim do średniego przystosowania populacji. W efekcie sprowadza to algorytm do losowego przeglądania przestrzeni rozwiązań.

Wykorzystanie metody  $\sigma$ -odcięcia pozwala na odrzucenie z populacji osobników o niskim przystosowaniu. Prowadzi to do szybkiego zbiegania się algorytmu. Efekt ten jest pogłębiany gdy w populacji znajdzie się grupa osobników o wysokim przystosowaniu. Wtedy nawet osobniki o stosunkowo przeciętnym przystosowaniu pierwotnym po skalowaniu  $\sigma$ -odcięciem będą ignorowane podczas etapu selekcji. Może to być pożądane zachowanie, na przykład gdy znamy możliwe miejsca rozwiązań.

#### 4.2 Metody selekcji

Z wykresów na stronach 2 i 2 widać, że stosowanie selekcji losowej jest korzystne gdy nie wiemy gdzie znajdują się rozwiązania problemu i chcemy przeszukać jak najwięcej możliwości. Na wykresach Rysunek 2 i Rysunek 4 można zauważyć faworyzację osobników o przeciętnym przystosowaniu przez selekcję losową. Nawet gdy istnieje grupa osobników o wyjątkowo wysokim przystosowaniu, osobniki o przeciętnym przystosowaniu wciąż mają przydzielane kopie w znacznych ilościach. Dzięki temu algorytm jest w stanie przejść przez wiele rozwiązań i zapobiega to przedwczesnemu zbiegnięciu algorytmu do jednego rozwiązania.

Selekcja deterministyczna może być pomocna gdy już wiemy, w którą stronę chcemy skierować algorytm. Pozwala dokładnie przebadać okolicę rozwiązania, które reprezentują osobniki dobrze przystosowane. Nie daje natomiast możliwości odejścia od rozwiązania osobników dobrze przystosowanych. Osobniki o gorszym przystosowaniu mają mniejsze możliwości reprodukcyjne, a przez to mniejszy wpływ na kierunek, w którym zdąża algorytm.